

Note méthodologique (Decliner-SO)


Groupe de travail « réussir l'appropriation de la science ouverte » – Comité pour la science ouverte (CoSO)

Sommaire

1 Description détaillée des phases de l'étude.....	3
1.1 Phases 1 et 2 : enquête exploratoire et observation des pratiques de « mise en données » (QUALI).....	3
1.2 Phase 3 : questionnaire « données et science ouverte » (QUANTI).....	5
1.3 Phase 4 : intégration et design (QUALI-QUANTI).....	6
2 Analyse du questionnaire.....	8
2.1 Obtention des résultats du questionnaire.....	8
2.2 Structuration et simplification des données.....	8
2.3 Analyse statistique.....	10
2.4 Construction des graphiques, des profils et des personae.....	12
2.5 Détail de codage concernant les réponses au questionnaire « données et science ouverte ».....	12
3 Références bibliographiques.....	14
3.1 Bibliographie citée dans la note méthodologique.....	14
3.2 Bibliographie de l'étude Décliner-SO.....	15
4 Crédits.....	18

1 | Description détaillée des phases de l'étude

L'étude Décliner la Science Ouverte (Decliner-SO) s'appuie sur des méthodes mixtes (Creswell 2013 ; Creswell and Clark 2011) afin d'intégrer à la fois une démarche qualitative et quantitative de recherche. Quatre phases se sont succédé impliquant au départ pour les deux premières phases une approche exploratoire qualitative (entretiens exploratoires puis d'observation des pratiques, *focus group*, journée d'étude, etc.) suivies d'une phase quantitative (questionnaire) et de son analyse. L'ensemble des informations collectées ont donné lieu à une dernière phase d'intégration (QUALI-QUANTI) avec une approche design (visualisations, *personae*, etc.) pour faciliter l'appropriation des résultats. (cf. Fig. 1 méthodologie de l'étude). Dans une démarche de science ouverte, les ressources méthodologiques, les informations et données recueillies dans l'étude sont mises à disposition dans le respect du règlement général des données personnelles ¹ (cf. Fig. 2 *workflow* de l'étude)



Résumé des différentes étapes de l'étude Décliner-SO (Fig.1) suivi de la chaîne de traitement des informations recueillies et de leur traitement (*workflow*) dans une démarche de science ouverte (Fig.2)

1.1 Phases 1 et 2 : enquête exploratoire et observation des pratiques de « mise en données » (QUALI)

Les deux premières phases de l'étude ont consisté en une démarche exploratoire qualitative (phase 1) suivie d'observation détaillée de pratiques (phase 2) par le biais d'entretiens et d'échanges avec différentes communautés de pratiques (*focus group*, journée d'étude). Au départ, le parti pris avait été

¹ Les transcripts d'entretiens ne sont pas mis à disposition, mais il est possible de les partager une fois anonymisé à d'autres équipes de recherche publique et membres du CoSO.

d'étudier séparément les pratiques associées aux données et à leur ouverture d'une part dans le champ des Sciences de la Vie et de la Santé et d'autre part dans celui des Sciences Humaines et Sociales.

Au vu de la vastitude de ces catégories disciplinaires et de ce qu'elles recoupent, le choix avait été en premier lieu de se concentrer dans le domaine de la santé et des sciences sur un objet de recherche commun : les virus à ARN. Une variété de personnes (ingénieur.e.s, doctorant.e.s, enseignant.e.s-chercheur.e.s, clinicien.ne.s, etc.) ont été interrogées dans le cadre aussi bien de recherche fondamentale ou clinique. Pour les Sciences Humaines et Sociales, le point de départ a été de se concentrer sur une discipline spécifique, celle de l'archéologie, et de porter attention plus spécifiquement à un outil de travail : le carnet de terrain/fouille (qui permet une documentation des étapes de la recherche - collecte, analyse et traitement d'informations/données.). Six entretiens exploratoires de plus d'une heure ont été conduits (4 « virus à ARN », 2 « archéologie »).

La deuxième phase de l'étude a consisté en une analyse plus poussée des pratiques numériques de « mise en données » (cf. 3 Références bibliographiques). Cela a pris la forme d'entretiens d'observations pour l'axe « virus à ARN ». Les personnes interrogées partageaient en amont un article de recherche et/ou un tableau de données qui servait de fil de directeur à l'entretien. Par le partage de leurs écrans, il était possible de mieux comprendre les différents outils employés et la chaîne de traitement (*workflow*) construite pour l'obtention des résultats. En parallèle de ces entretiens, pour la partie Sciences Humaines et Sociales, une journée d'étude a été organisée avec différents profils (doctorant.e.s, chercheur.e.s, ingénieur.e.s, maître.sse de conférence, post-doctorant.e.s) et disciplines représentées (histoire, sociologie, sciences de l'information et de la communication, littérature, linguistique, etc.). L'objectif était que chacun.e puisse montrer les « coulisses de sa recherche ». Chaque personne (une vingtaine de participant.es) a pendant une journée (en ligne) partagé ses pratiques associées aux « données » (constitution de bases de données, collecte d'informations via des archives, numérisation, etc.), des outils employés (langage de programmation, FileMaker, Nakala, etc.), les difficultés rencontrées tout autant que les facteurs de réussite (notamment la constitution de binômes chercheur.e.s/ingénieur.e.s dont les interactions sont basées sur une écoute mutuelle). L'ensemble des interventions a fait l'objet d'un résumé sous forme d'une présentation qui a été relu par chacun et chacune (avec l'accord de mise à disposition en ligne).

Les informations recueillies tout au long des phases qualitatives (entretiens, journées d'étude, groupe de travail avec les membres de l'équipe) ont fait l'objet au fur et à mesure d'une analyse par théorisation ancrée. Cette méthode d'analyse d'informations qualitatives permet par un ensemble d'étape codifié et une démarche itérative de dégager une modélisation d'un phénomène observé (Paillé 1994; Lejeune 2014). Que ce soit les transcriptions d'entretiens, les prises de notes lors des réunions du groupe de travail (*focus group*)², les présentations de la journée, ces éléments par itération successive ont permis en premier lieu de préciser les problématiques de recherche. Ensuite, de dégager différents concepts sensibilisateurs théoriques aidant à cheminer dans les résultats. En termes de concepts sensibilisateurs théoriques, celui de « mise en données » fut clef pour montrer que tout au long du travail de recherche, avant même de penser le partage et l'ouverture des données, un ensemble d'étapes souvent invisibilisées sont nécessaires pour donner naissance à des « données ». D'autres

2 Certaines réunions en équipe ont constitué des *focus group* dans le sens où l'analyse menée par Célya Gruson-Daniel faisait l'objet d'une discussion collective par l'ensemble des membres du groupe venant de disciplines variées et de différentes professions ; chacune amenant à son tour des précisions ou retours d'expérience sur la thématique évoquée en fonction de ses connaissances et pratiques de recherche ou d'accompagnement à la recherche. Un *focus group* a été réalisé après chaque grande phase.

concepts sensibilisateurs tels que *data journey*, datafication, public des données, interfaces ont aidé au cheminement d'analyse (Dourish and Gómez Cruz 2018; Jaton and Vinck 2016; Heaton and Millerand 2013; Ankeny 2020; Leonelli 2020; Vial 2016; Bastin and Francony 2016)]. Suite à ces deux phases qualitatives, plusieurs hypothèses ont été étayées et ont donné lieu à la construction d'un questionnaire « données et science ouverte » pour y apporter des réponses sur la base d'une population plus large et plus représentative d'une diversité de disciplines au sein de l'enseignement supérieur et de la recherche.

1.2 Phase 3 : questionnaire « données et science ouverte » (QUANTI)

Un questionnaire (phase quanti) a été conçu dans le but de répondre à différentes hypothèses intermédiaire issues des deux phases qualitatives. En effet, il s'agissait de mieux comprendre les éléments-clefs permettant de différencier différents rapports et pratiques associées aux données. Trois grandes hypothèses intermédiaires avaient été soulignées :

- la discipline explique les différences de pratiques open science (en relation avec les données : mise en données, ouverture, etc.). Cette hypothèse initiale était celle portée par les membres du groupe de travail ayant donné lieu à la proposition de cette étude.
- les différentes démarches de recherche (avec des plus-values distinctes) expliquent des comportements différents en lien avec les données. Cette hypothèse a émergé principalement avec les phases qualitatives (usage de la notion de communautés épistémiques).
- le statut et le travail plus ou moins collectif (communautés de pratiques et de partage de savoir-faire) expliquent les différences de pratiques (utilisation logiciel, mode de formation, pratiques de partages, etc.).

Pour y répondre, la trame du questionnaire se composait de 5 parties :

1. cadre et démarche de recherche
2. pratiques de mise en données
3. collectifs et environnement de travail
4. accompagnements et besoins
5. affiliation, fonctions et champs disciplinaires

Le questionnaire a recueilli plus de 429 réponses complètes. Les questions fermées (35 questions sur 43) ont fait l'objet d'une analyse statistique descriptive univariée (tris à plat et tris croisés) suivie d'une analyse descriptive multivariée (ACM puis HCPC) (cf. 2 Analyse du questionnaire). Les analyses ont été menées suite à la pondération des résultats en fonction des catégories disciplinaires en se servant comme référentiel des données 2019-2020 de L'état de l'Enseignement supérieur, de la Recherche et de l'Innovation en France (n°14 – Avril 2021)(SIES, Sous-direction des systèmes d'information et des études statistiques, Ministère de l'Enseignement supérieur, de la Recherche et de l'Innovation, and France 08).

L'ensemble des résultats obtenus ont été analysés en croisant les informations qualitatives des phases précédentes donnant lieu à la dernière phase de l'étude (quali-quanti).

Résumé synthétique de la méthodologie d'analyse du questionnaire détaillée dans la partie 2.

Analyse du questionnaire

0. Exportation des résultats (.csv) du questionnaire réalisé sur limesurvey.
réponses complètes seulement (429 réponses)
1. Simplification/préparation des données
sous Libre Office Calc
pondération des données pour être représentatif de la répartition des disciplines en ESR
2. Analyse statistique descriptive univariée
tris à plat
tris croisés
3. Analyse statistique multivariée
ACM HCPC séparant deux dimensions (pratiques « open science » et contexte de recherche)

Utilisation de Libre Office Calc pour la préparation des données puis de R pour les analyses statistiques.

1.3 Phase 4 : intégration et design (QUALI-QUANTI)

Une première analyse des résultats du questionnaire a été effectuée sur la base des tris à plat ; ces derniers ont permis de prévoir la réalisation de tris croisés afin de définir en détail les facteurs différenciant les différentes pratiques associées aux données.

En parallèle, l'analyse multivariée a aidé à constituer une typologie de pratiques basée sur 5 grands profils (issus des ACM et de la classification automatique HCPC), dont 4 sont présentés (le cinquième correspondant à des personnes non concernées). Ces résultats ont été affinés par l'analyse des réponses qualitatives du questionnaire et l'intégration des analyses précédentes (phase 1 et phase 2).

Une approche *design* a été mobilisée pour faciliter la lecture des visualisations produites et l'appropriation des résultats. Outre la réalisation des graphiques sur datawrapper pour les tris à plat, une heatmap correspondant aux 4 profils-types principaux a été aussi réalisée pour faciliter la lecture des facteurs clefs différenciant les différents profils. Enfin, des *personæ* ont été construites afin d'illustrer l'ensemble des caractéristiques dans des personnages fictifs (2 par profil). Ces personnages s'inspirent des caractéristiques clefs sur-représentés dans chaque profil, avec l'ajout d'éléments spécifiques marquants issus des phases qualitatives de l'étude.

Points de vigilance :

Il est important de distinguer la méthodologie de construction des profils (typologie de pratiques) et des *personæ* (personnages fictifs) :

- Les profils se basent sur les résultats d'une ACM (Analyse des Correspondances Multiples) et d'une classification automatique (procédure HCPC de FactoMineR) qui permettent de distinguer différentes classes. Ces dernières indiquent des sur-représentations de modalités de variables du questionnaire pour une classe donnée. Cela ne signifie pas que ces modalités sont majoritaires dans la classe.
- Les *personæ* sont des personnages fictifs, constitués à partir de l'exploration des réponses au questionnaire (les plus représentatives de chaque classe) en se nourrissant des résultats des phases d'analyse qualitative (journée d'étude, entretiens exploratoire et de pratiques) dans le but de mettre en contexte les profils et faire ressortir plus spécifiquement des points saillants.

Le rapport final sous la forme d'une présentation synthétique a été rédigé sur la base de l'ensemble des informations et données analysées dans les différentes phases (aussi bien qualitatives que quantitative). Des réponses sont apportées successivement aux deux problématiques posées avec d'une part la mise en avant des profils types et des personæ et des facteurs principaux différenciant les pratiques (problématique 1) et d'autre part la description de 5 pistes d'orientation pour mieux accompagner les pratiques (problématique 2) associées à 20 recommandations.

2 | Analyse du questionnaire

2.1 Obtention des résultats du questionnaire.

Le questionnaire a été réalisé via le logiciel open source limesurvey (instance installée sur les serveurs d'Inno³). Le questionnaire comportait 43 questions dont 8 questions ouvertes réparties en 4 parties.

- Cadre et démarche de recherche (5 questions)
- Pratiques de mises en données (2.1 avec 5 questions) et mise à disposition et réutilisation des données (2.2 avec 8 questions)
- Collectifs et environnement numérique de travail (9 questions)
- Accompagnement et besoins (8 questions)
- Affiliations, fonctions et champs disciplinaires (8 questions)

429 réponses complètes ont été obtenues suite à la diffusion du questionnaire entre le 19 mai 2021 et le 25 juin 2021.³ Le questionnaire a été relayé par les membres du groupe de travail sur des listes de diffusion de différentes disciplines (histoire, socio, eco, interdisciplinaire, physique, informatique) et thématiques (accès ouvert, méthodologie, traitement de données, administration) et au sein de différents instituts (INRAE, CIRAD, Institut Pasteur, etc.) notamment par le biais des personnes interrogées lors des entretiens.

Les réponses (complètes seulement) au questionnaire ont été exportées sous format csv pour être analysées. Les données du questionnaire ont été partagées sur **XXX**. Il a été vérifié qu'aucun nom et prénom n'était mentionné⁴.

2.2 Structuration et simplification des données

Plusieurs étapes préliminaires ont été effectuées avant de pouvoir opérer les traitements statistiques.

- suppression des colonnes concernant les questions ouvertes (commentaires, réponses « autre » détaillées) ;
- codage des variables (fichier de correspondances anciens-nouveaux noms conservé dans le fichier.ods) ;
- remplacement des cases vides et des N/A de Limesurvey (= question conditionnelle non posée) par NA (code de R pour les données manquantes) ;
- regroupement de certaines réponses (à faibles effectifs) aux questions fermées à partir d'un premier tri à plat automatisé dans R (ex : fonctions rares regroupées dans « autre ») ;
- un recodage des disciplines de la question 40 :
 - « autres » pour les personnes qui ont répondu 1/ « non » à toutes les propositions 2/ seulement « pluridisciplinaire » ou 3/ à la fois ST et LSH ou ST et DE ou LSH et DE.

3 Accès à l'annonce du questionnaire sur Inno³ : <https://inno3.fr/actualite/enquete-sur-les-pratiques-associees-la-production-et-diffusion-des-donnees-en-recherche>.

4 En cet état, le questionnaire est pseudonymisé (vérification qu'aucune information personnelle permet de retrouver directement la personne)¹

- « ST » pour inclure les réponses informatiques et sciences des données et/ou mathématiques et/ou sciences de la vie et/ou ingé et/ou matière et/ou terre avec éventuellement pluridisciplinaire (non « autres ») mais ni droit, économie et gestion ni lettres et sciences humaines ;
- « LSH » pour inclure les réponses lettres et sciences humaines avec éventuellement pluridisciplinaire (non « autres ») mais aucune des autres catégories ;
- « DE » pour inclure droit, économie et gestion avec éventuellement pluridisciplinaire (non « autres ») mais aucune des autres catégories ;

2.2.1 Disciplines représentées et choix de pondération des résultats

Dans le questionnaire, deux questions portaient sur la ou les disciplines de recherche des personnes interrogées. La question fermée (40) proposait de choisir entre grandes catégories disciplinaires (lettres et sciences humaine et sociales, droit économie, sciences de la vie, etc.). Une question ouverte (41) permettait aux participant·e·s de préciser leurs spécialités.

Les résultats au questionnaire donnaient une sur-représentation de la catégorie « Lettres et Sciences Humaines et Sociales » (LSH) par rapport à la répartition disciplinaire au sein de l'ESR (environ 61 % des réponses avec principalement de la sociologie et de l'histoire contre 11 % dans le domaine des sciences de la vie et de la santé).⁵

Pour cette raison, nous avons effectué une pondération des résultats afin d'arriver à un échantillon représentatif de la répartition disciplinaire dans l'ESR en nous basant sur les données du rapport de l'état de l'ESR en France qui publie chaque année la répartition des enseignants en fonction, par grande discipline et catégorie (cf encadré suivant.). Nous avons choisi de pondérer les catégories : Droit, économie et gestion, Lettres et sciences humaines et Sciences et Technique. Les « autres » n'ont pas été pondérés.

Les coefficients suivants ont été appliqués : Autres : 1, DE : 3,4, LSH : 0,6, ST : 1,4 (sans prendre en considération la catégorie santé au sens médecine-pharmacie-dentaire, absente parmi nos répondant·es).

L'ensemble des analyses statistiques présentes dans l'étude prend en considération les résultats pondérés en fonction des disciplines. Malgré cette pondération, peu de différences se retrouvent dans les réponses apportées aux questions. De plus, le nombre de réponses plus importantes de personnes issues des LSH a permis d'explorer plus en finesse une diversité de pratiques au sein de ces disciplines (notamment par le biais des réponses qualitatives apportées dans le questionnaire) et la détermination des profils (ACM).

Données 2019-2020 ESR – L'état de l'Enseignement supérieur, de la Recherche et de l'Innovation en France (n°14 – Avril 2021)

Répartition des enseignants en fonction dans l'enseignement supérieur par catégorie et type d'établissement en 2019-20 (en %) – Par catégorie

- Professeurs des universités (22 %)

⁵ Les réponses apportées au questionnaire provenaient de :+ LSH 56 % – DE 5 % – ST 29 % et autres 10 %].

- Maîtres de conférences (38 %)
- Enseignants du 2nd degré (14 %)
- Enseignants contractuels (26 %)
- Enseignant-chercheurs 60 %

Répartition des enseignants en fonction dans l'enseignement supérieur par catégorie et type d'établissement en 2019-20 (en %) – Par type d'établissement

- Universités (92 %)
- Écoles d'ingénieurs (ENI, INP, INSA, Écoles centrales, ENS Chimie.) (4 %)
- Autres établissements(ENS, IEP, grands établissements.) (4 %)

Répartition des enseignants en fonction dans l'enseignement supérieur par grande discipline et catégorie en 2019-20 1 (en personnes physiques, en %)

- Droit, Sciences économiques et de gestion (15 %)
- Lettres et Sciences humaines (31 %)
- Sciences et techniques (39 %)
- Santé (médecine, odontologie, pharmacie) (14 %)

2.3 Analyse statistique

2.3.1 Analyse statistique descriptive

Chaque question a fait l'objet d'une analyse statistique descriptive (tris à plat) donnant lieu à la réalisation de graphiques (cf. Construction des graphiques, des profils et des personae). Concernant les tris croisés (avec test de Chi2), ces derniers ont été réalisés sur certaines questions seulement afin de comprendre en finesse les facteurs différenciant les pratiques associées aux données. Par exemple, toutes les corrélations avec les autres réponses ont été explorées pour ce qui concerne l'environnement de travail (terrain, labo, clinique), les qualificatifs associés aux données, ou encore à la qualité en recherche, ce qui a permis notamment de construire le tableau démarches de recherche de l'étude (cf. résumé directif ou rapport synthétique).

2.3.2 Analyse statistique multivariée

Analyse des correspondances multiples (ACM)

Les ACM cherchent à représenter l'espace des positions en fonction de variables considérées comme actives et illustratives.

Le choix ici a été de distinguer deux types de variables :

1. les pratiques associées aux données dans le cadre de la mise en œuvre de politique « science ouverte » (principes FAIR, incitation à la reproductibilité, structuration de l'accompagnement et de formations). Les variables qui les concernent sont actives dans l'analyse dont les résultats sont présentés dans le rapport.
2. les informations générales sur les personnes et leur environnement de travail et démarche employées. Il s'agit par exemple des infos générales (statut, genre, etc.) ou des informations sur leur environnement de travail et leur démarche de travail (leur plus-value selon eux/elles, taille

des équipes, logiciels utilisés). Les variables qui les concernent sont illustratives dans l'analyse dont les résultats sont présentés dans le rapport.

NB. La question « à quoi passez-vous du temps ? » a été considérée comme variable « environnement/démarche de recherche », tout comme les sources et les types de production.

2.3.2.1 ACM : étapes et procédures utilisées

Suite à la génération de premières ACM permettant de faire ressortir différents axes (cf. encadré suivante), une classification automatique a été réalisée. La classification a été obtenue avec la procédure [HCPC](#) (Husson, Lê, and Pagès 2020; 2016), qui prend en compte les cinq premiers axes de l'ACM et permet une analyse plus fine.

Rappel : extrait du carnet de bord - axes clefs différenciant la première analyse ACM

1. culture « computationnelle et du libre » c'est-à-dire qui ont une expérience de gestion de données, de développement de codes source accompagné à une culture du libre et de l'open (pratique collaborative de développement de codes sources, regard sur la sécurité des données, connaissance des modalités de partage et d'ouverture).
2. culture « académique et intellectuelle » travail seul, mise à disposition non considérée comme possible
3. rapport au soutien et à l'aide à apporter pour des changements de pratique :
 1. volonté d'être aidé soutenu de différentes manières (techniques, soutien par des formations) à diverses étapes avec à la fois des personnes qui peuvent demander de l'aide ou bien des personnes qui aident déjà (lien avec culture open/libre)
 2. non concerné et non applicable
4. Rapport au partage et à la réutilisation
 - non concerné ou négatif
 - positif mais qui partagent sur des sites web ou des disques amovibles plutôt que par des moyens plus FAIR.

Au départ, deux versions de l'ACM ont été réalisés, en permutant les variables actives et illustratives, pour avoir d'une part une typologie portant sur 1/ l'évolution des pratiques associées aux données avec la science ouverte (et ceux qui les différencient) et d'autre part une typologie centrée sur 2/ les démarches de recherche et l'environnement de travail (cadre de travail, travail collectif ou individuel, etc.).

Dans la suite de l'étude, seule l'ACM 1/ « évolution des pratiques associées aux données avec la science ouverte » a été sélectionnée. 5 classes ont été distinguées afin de dissocier plus précisément deux types de classes (2 et 3) qui sont assez proches mais apportent quelques nuances intéressantes sur des différences de profils. Les classes 2 et 3 correspondent aux profils intitulés respectivement

collaboratifs et solitaires dans l'étude et regroupent essentiellement des spécialistes de SHS. Il ne faut donc pas surinterpréter les différences entre elles. La classe 1, quant à elle, n'a pas été mise en avant dans la présentation des résultats finaux, car elle représentait la classe regroupant principalement des N.A, c'est-à-dire des personnes dont les non réponses indiquent qu'elles ne se sont en réalité pas senties très concernées par le questionnaire.

2.4 Construction des graphiques, des profils et des personae

L'outil datawrapper a été utilisé pour réaliser les graphiques à partir des résultats des tris à plat (%) pour chaque modalité, en s'intéressant aux « oui » dans le cas de questions à choix multiples.

Pour la heatmap, pour chaque profil issu de l'ACM « évolution des pratiques associées aux données », dans le cas de modalités binaire oui/non, seules les modalités positives ont été conservées (le négatif étant redondant, car il représentait l'opposé). Les modalités « non applicables », lorsqu'elles correspondaient à une représentation « positive » (informatives sur les réalités des pratiques), ont été gardées, tout comme les diverses modalités proposées pour les réponses à choix multiple. Les 10 v-tests les plus élevés ont été conservés pour les modalités de variables actives (associées à « l'évolution des pratiques associées aux données et science ouverte ») et les 8 v-tests les plus élevés pour les modalités de variables illustratives, décrivant la démarche de recherche et l'environnement de travail.

Les 4 profils reprennent les éléments clefs du résultat de l'ACM puis HCPC. Les modalités les plus sur-représentées (représentées dans la *heatmap*) sont indiquées en gras. Les autres modalités indiquées correspondent aux autres corrélations ayant un v-test positif. Les profils représentent les modalités sur-représentées dans une des classes, sans que cela signifie que celles-ci soient majoritaires dans cette classe.

Les personae sont issues de l'analyse quantitative (détermination des profils) et qualitative (entretiens, journées d'étude, commentaires qualitatifs du questionnaire). En effet, ces personnages fictifs s'inspirent des caractéristiques clefs sur-représentées dans chaque classe, ainsi que des connaissances issues des 13 entretiens menés dans la phase qualitative et de l'analyse des réponses détaillées des participant·e·s les plus représentatifs de chaque classe ou ayant fourni un grand nombre de commentaires qualitatifs.

2.5 Détail de codage concernant les réponses au questionnaire « données et science ouverte »

2.5.1 question 28 sur les spécialités disciplinaires

Regroupement des réponses en fonction des qualificatifs associés : par exemple les réponses comprenant « socio » ont été codées en sociologie, « bio » en biologie à l'exception d'histoire de l'art et histoire du droit (non associées à « histoire » et mis dans « autre »). Dans le cas de moins de 10 réponses dans une catégorie, celles-ci sont placées dans « autre » (cas par ex de l'informatique ou de l'économie). Le choix a été fait également de classer les réponses précisant deux disciplines dans « autre »).

2.5.2 question 13 limites mise à disposition

La hiérarchisation a été ignorée, on considère que chaque personne a mis « oui » sur 1 à 4 limites. On se limite aux 5 modalités listées dans le tableau ci-dessus. On met « non » sur les 5 modalités aux gens qui n'ont pas répondu du tout à la question.

3 | Références bibliographiques

Concepts théoriques et ressources bibliographiques

- **Mise en (base de) données, travail des données, data journey, datafication** : des concepts issus des travaux en STS, SIC, anthropologie des connaissances
- **Les données : un construit**. Une « donnée » a une valeur, une finalité pour les personnes qui les manipulent. Une information peut-être considérée comme donnée (ou non) en fonction du projet de recherche (ex. images dans une publication en archéologie)
- **La mise en données : un ensemble d'étapes** qui permet à partir de sources/ressources de produire des jeux de données/bases de données sur lesquels s'appuie une recherche/étude (critère de scientificité) avec la production de visualisation et d'une « narration » sur les données
- Il existe différentes étapes dans la mise en donnée avec la production d'artefacts (version intermédiaire) qui **tendent souvent à être invisibilisées** (ainsi que les personnes y participant).

Résumé de quelques concepts clefs ayant été mobilisés lors de l'étude Décliner-SO

3.1 Bibliographie citée dans la note méthodologique

- Ankeny, Rachel A. 2020. "Tracing Data Journeys Through Medical Case Reports: Conceptualizing Case Reports Not as 'Anecdotes' but Productive Epistemic Constructs, or Why Zebras Can Be Useful." In *Data Journeys in the Sciences*, edited by Sabina Leonelli and Niccolò Tempini, 59–76. Cham: Springer International Publishing. https://doi.org/10.1007/978-3-030-37177-7_4.
- Bastin, Gilles, and Jean-Marc Francony. 2016. "L'inscription, le masque et la donnée." *Revue d'anthropologie des connaissances* 10, n° 4 (4): 505–30.
- Creswell, John W. 2013. *Research Design: Qualitative, Quantitative, and Mixed Methods Approaches*. SAGE.
- Creswell, John W., and Vicki L. Plano Clark. 2011. *Designing and Conducting Mixed Methods Research*. SAGE.
- Dourish, Paul, and Edgar Gómez Cruz. 2018. "Datafication and Data Fiction: Narrating Data and Narrating with Data." *Big Data & Society* 5 (2): 2053951718784083. <https://doi.org/10.1177/2053951718784083>.
- Heaton, Lorna, and Florence Millerand. 2013. "La mise en base de données de matériaux de recherche en botanique et en écologie." *Revue d'anthropologie des connaissances* 7 (4): 885–913.
- Husson, François, Sébastien Lê, and Jérôme Pagès. 2016. *Analyse de données avec R*. 2e éd. revue et augmentée. Pratique de la statistique. Rennes: Presses universitaires de Rennes.
- . 2020. *Exploratory Multivariate Analysis by Example Using R*. Taylor & Francis Limited.
- Jaton, Florian, and Dominique Vinck. 2016. "Processus frictionnels de mises en bases de données." *Revue d'anthropologie des connaissances* 10 (4): 489–504.
- Lejeune, Christophe. 2014. *Manuel d'analyse qualitative. Analyser sans compter ni classer*. Louvain-La-Neuve: De Boeck Supérieur. <http://orbi.ulg.ac.be/handle/2268/172944>.
- Leonelli, Sabina. 2020. "Learning from Data Journeys." In *Data Journeys in the Sciences*, edited by Sabina Leonelli and Niccolò Tempini, 1–24. Cham: Springer International Publishing. https://doi.org/10.1007/978-3-030-37177-7_1.
- Paillé, Pierre. 1994. "L'analyse par théorisation ancrée." *Cahiers de recherche sociologique*, no. 23: 147. <https://doi.org/10.7202/1002253ar>.

SIES, Sous-direction des systèmes d'information et des études statistiques, Ministère de l'Enseignement supérieur, de la Recherche et de l'Innovation, and France, eds. 08. *L'État de l'Enseignement supérieur, de la Recherche et de l'Innovation en France 2021*. Paris: SIES.

Vial, Stéphane. 2016. "Le tournant design des humanités numériques." *Revue française des sciences de l'information et de la communication*, no. 8 (January). <https://doi.org/10.4000/rfsic.1828>.

3.2 Bibliographie de l'étude Décliner-SO

- Amiel, Philippe, Francesca Frontini, Pierre-Yves Lacour, and Agnès Robin. 2020. "Pratiques de gestion des données de la recherche : une nécessaire acculturation des chercheurs aux enjeux de la science ouverte ?. Résultats d'une enquête exploratoire dans le bassin montpelliérain (juin 2018)." *Cahiers Droit, Sciences & Technologies*, no. 10 (May): 147–68. <https://doi.org/10.4000/cdst.2061>.
- Baribeau, Colette. 2005. "L'instrumentation dans la collecte de données - Le journal de bord du chercheur" *Hors-Série* (2): 17.
- Bechtel, William. 2020. "Data Journeys Beyond Databases in Systems Biology: Cytoscape and NDEx." In *Data Journeys in the Sciences*, edited by Sabina Leonelli and Niccolò Tempini, 121–43. Cham: Springer International Publishing. https://doi.org/10.1007/978-3-030-37177-7_7.
- Boukala, Mouloud, and Serge Proulx. 2020. "Politique et reconfiguration des méthodes de sciences humaines et sociales à l'ère de la transition numérique. Entretien avec Serge Proulx." *Parcours anthropologiques*, no. 15 (July): 27–38. <https://doi.org/10.4000/pa.888>.
- Boumans, Marcel, and Sabina Leonelli. 2020. "From Dirty Data to Tidy Facts: Clustering Practices in Plant Phenomics and Business Cycle Analysis." In *Data Journeys in the Sciences*, edited by Sabina Leonelli and Niccolò Tempini, 79–101. Cham: Springer International Publishing. https://doi.org/10.1007/978-3-030-37177-7_5.
- Charrier, Philippe, and Mariannig Le Béhec. 2020. "méthodologie – SOSP-FR." 2020. <https://ecosysteme.hypotheses.org/category/methodologie>.
- Dillaerts, Hans, Céline Paganelli, Lise Verlaet, and Hugo Catherine. 2020. "Usages et pratiques en lien avec les données de recherche. Une enquête menée auprès des chercheurs de l'université Paul-Valéry Montpellier 3." Report, Université Paul-Valéry Montpellier 3. <https://doi.org/10/document>.
- Dourish, Paul, and Edgar Gómez Cruz. 2018. "Datafication and Data Fiction: Narrating Data and Narrating with Data." *Big Data & Society* 5 (2): 2053951718784083. <https://doi.org/10.1177/2053951718784083>.
- DUPRAT, Julie. 2019. "Les Données de La Recherche à l'Université Bordeaux Montaigne." Research Report. Université Bordeaux Montaigne. <https://hal.archives-ouvertes.fr/hal-02020141>.
- Dymytrova, Valentyna, and Françoise Paquienséguy. 2020. "Du Traitement Des Données à La Création de Valeur : Comprendre Les Pratiques Professionnelles Des Réutilisateurs Des Données Ouvertes." *Des Données à La Décision-From Data to Decisions*, August. <https://hal.archives-ouvertes.fr/hal-02913346>.
- Galleron, Ioana, and Fatiha Idmhand. 2020. "De l'interopérabilité à la réutilisabilité des éditions électroniques." *Humanités numériques*, no. 1 (January). <http://journals.openedition.org/revuehn/350>.

- Griesemer, James. 2020. "A Data Journey Through Dataset-Centric Population Genomics." In *Data Journeys in the Sciences*, edited by Sabina Leonelli and Niccolò Tempini, 145–67. Cham: Springer International Publishing. https://doi.org/10.1007/978-3-030-37177-7_8.
- Halfmann, Gregor. 2020. "Material Origins of a Data Journey in Ocean Science: How Sampling and Scaffolding Shape Data Practices." In *Data Journeys in the Sciences*, edited by Sabina Leonelli and Niccolò Tempini, 27–44. Cham: Springer International Publishing. https://doi.org/10.1007/978-3-030-37177-7_2.
- Jones, Kristal, Steven Alexander, Libby Bishop, Amber Budden, Michael Cox, Merce Crosas, Sebastian Karcher, et al. 2018. *Qualitative Data Sharing and Re-Use for Socio-Environmental Systems Research: A Synthesis of Opportunities, Challenges, Resources and Approaches*. <https://doi.org/10.13016/M2WH2DG59>.
- Leonelli, Sabina. 2020a. "Learning from Data Journeys." In *Data Journeys in the Sciences*, edited by Sabina Leonelli and Niccolò Tempini, 1–24. Cham: Springer International Publishing. https://doi.org/10.1007/978-3-030-37177-7_1.
- . 2020b. "Learning from Data Journeys." In *Data Journeys in the Sciences*, edited by Sabina Leonelli and Niccolò Tempini, 1–24. Cham: Springer International Publishing. https://doi.org/10.1007/978-3-030-37177-7_1.
- Mancilla, Heather Andrews, Marta Teperek, Jasper van Dijck, Kees den Heijer, Robbert Eggermont, Esther Plomp, Yasemin Turkyilmaz-van der Velden, and Shalini Kurapati. 2019. "On a Quest for Cultural Change - Surveying Research Data Management Practices at Delft University of Technology." *LIBER Quarterly* 29 (1): 1–27. <https://doi.org/10.18352/lq.10287>.
- Mejias, Ulises A., and Nick Couldry. 2019. "Datafication." *Internet Policy Review* 8 (4). <https://policyreview.info/concepts/datafication>.
- Olivier de Sardan, Jean-Pierre. 1995. "La politique du terrain. Sur la production des données en anthropologie." *Enquête. Archives de la revue Enquête*, no. 1 (October): 71–109. <https://doi.org/10.4000/enquete.263>.
- Ortiz Caria, Alexandra, and Camille Noûs. 2019. "Fabriquer un corpus de données en analyse de conversation. Fondements théoriques, enjeux réflexifs et pratiques collectives." *Tracés. Revue de Sciences humaines*, no. #19 (December): 67–88. <https://doi.org/10.4000/traces.10688>.
- Parsons, M. A., and P. A. Fox. 2013. "Is Data Publication the Right Metaphor?" *Data Science Journal* 12: WDS32–46. <https://doi.org/10.2481/dsj.WDS-042>.
- Porter, Theodore M. 2020. "Most Often, What Is Transmitted Is Transformed." In *Data Journeys in the Sciences*, edited by Sabina Leonelli and Niccolò Tempini, 229–36. Cham: Springer International Publishing. https://doi.org/10.1007/978-3-030-37177-7_12.
- Prost, Hélène, and Joachim Schöpfel. 2015. "Les données de la recherche en SHS. Une enquête à l'Université de Lille 3." Report, Lille 3. <https://hal.univ-lille.fr/hal-01198379>.
- Rebouillat, Violaine. 2019. "Ouverture des données de la recherche : de la vision politique aux pratiques des chercheurs." Phdthesis, Conservatoire national des arts et metiers - CNAM. <https://tel.archives-ouvertes.fr/tel-02447653>.

- Serres, Alexandre, Marie-Laure Malingre, Morgane Mignon, Cécile Pierre, and Didier Collet. 2017a. "Données de La Recherche En SHS. Pratiques, Représentations et Attentes Des Chercheurs : Une Enquête à l'Université Rennes 2." Research Report. Université Rennes 2. <https://hal.archives-ouvertes.fr/hal-01635186>.
- . 2017b. "Practices, Mental Images and Expectations of Researchers about Research Data in the Humanities : A Survey at Rennes 2 University." Research Report. Université Rennes 2. <https://hal.archives-ouvertes.fr/hal-01635186>.
- Stefan Le Courant, Anthony Pecqueux, and Camille Noûs. 2020. "Archiver, Documenter, Enquêter Sur l'enquête Qualitative. Le Travail de l'ombre de BeQuali." *Tracés. Revue de Sciences Humaines*.
- "Survey: Research Data Management Practice." 2018, January. <https://osf.io/54em6/>.
- TU Delft Data Stewards, EPFL Library Research Data Team, Jan Krause, Nathalie Lambeng, Heather Andrews, Jasmin Boehmer, Maria Cruz, et al. 2018a. "Quantitative Assessment of Research Data Management Practice." Zenodo. <https://doi.org/10.5281/ZENODO.1168800>.
- . 2018b. "Quantitative Assessment of Research Data Management Practice." Zenodo. <https://doi.org/10.5281/zenodo.3380332>.
- Vanlint, Alice. 2019. "Le journal de bord ou de terrain." In *Guide décolonisé et pluriversel de formation à la recherche en sciences sociales et humaines*. Éditions science et bien commun. <https://scienceetbiencommun.pressbooks.pub/projetthese/chapter/le-journal-de-bord-ou-de-terrain/>.
- Vial, Stéphane. 2016. "Le tournant design des humanités numériques." *Revue française des sciences de l'information et de la communication*, no. 8 (January). <https://doi.org/10.4000/rfsic.1828>.
- Weber, Florence. 1991. "L'enquête, la recherche et l'intime ou : pourquoi censurer son journal de terrain ?" *Espace Temps* 47 (1): 71–81. <https://doi.org/10.3406/espat.1991.3788>.

4 | Crédits

La note méthodologique a été rédigée par Célya Gruson-Daniel, qui a réalisé l'analyse qualitative de l'étude puis relue et corrigée par Claire Lemerrier, qui a réalisé la partie quantitative de l'étude.

La note méthodologique (texte et graphique) est disponible sous licence [CC BY 4.0](https://creativecommons.org/licenses/by/4.0/).